

DOCUMENTACIÓN TÉCNICA

Detección de Fraude Financiero con Machine Learning

Proyecto Final Talendig 1ra Cohorte - Carrera técnica en Data Science

Resumen

El presente proyecto tiene como objetivo desarrollar una solución integral para la detección de fraude financiero mediante técnicas de Ciencia de Datos, Machine Learning y Business Intelligence.

La iniciativa fue construida utilizando un dataset sintético de aproximadamente 600,000 registros, diseñado específicamente para simular escenarios reales de instituciones financieras, incluyendo transacciones válidas, transacciones fraudulentas y registros con problemas de calidad de datos.

El proyecto fue estructurado siguiendo el flujo real de un proyecto de analítica avanzada:

1. Evaluación y limpieza de datos.
2. Análisis exploratorio.
3. Detección de anomalías.
4. Entrenamiento de modelos predictivos.
5. Construcción de dashboards ejecutivos.

El resultado final es una plataforma capaz de monitorear operaciones financieras, identificar patrones sospechosos y evaluar el desempeño de distintos enfoques de detección de fraude.

1.Problema de Negocio

Las instituciones financieras procesan diariamente grandes volúmenes de transacciones a través de distintos canales y productos financieros.

Entre estas operaciones pueden existir actividades fraudulentas que generan:

- pérdidas económicas,
- riesgos regulatorios,
- deterioro de la confianza de los clientes,
- costos operativos asociados a investigaciones.

Ante este escenario, las organizaciones necesitan herramientas capaces de detectar tempranamente transacciones sospechosas y priorizar esfuerzos de monitoreo.

El propósito de este proyecto es demostrar cómo la Ciencia de Datos puede apoyar estos procesos mediante el análisis de comportamiento transaccional y modelos predictivos.

2. Diseño del Dataset

A diferencia de utilizar datos reales, el proyecto emplea un dataset sintético especialmente diseñado para fines educativos y de simulación.

El diseño del dataset sigue reglas de negocio coherentes con el comportamiento de clientes financieros reales.

Estructura general

Total de registros:

- 600,000 registros

Compuestos por:

- 500,000 transacciones válidas
- 100,000 registros con problemas de calidad

Clientes simulados:

- 7,000 clientes

Período analizado:

- 3 meses de actividad financiera

Perfil de los clientes

Cada cliente fue generado con características económicas y financieras consistentes.

Entre ellas:

- ocupación,
- industria,
- tipo de empleo,
- ingreso mensual,
- frecuencia de ingreso,
- antigüedad como cliente,
- segmento transaccional,
- canal habitual,
- producto financiero habitual,
- perfil de riesgo.

Esto permite construir comportamientos realistas y diferenciados para cada usuario.

Construcción del fraude

El fraude no fue generado aleatoriamente.

Las transacciones fraudulentas fueron diseñadas como anomalías respecto al comportamiento histórico del cliente.

Para ello se consideraron factores como:

- montos significativamente superiores al promedio habitual,
- utilización de canales no frecuentes,
- uso de productos financieros inusuales,
- operaciones fuera del horario habitual,
- incremento del nivel de riesgo.

Esta lógica permite simular situaciones similares a las que enfrentan los sistemas antifraude reales.

3. Calidad y Preparación de Datos

Antes de realizar cualquier análisis, se ejecutó una fase completa de preparación y validación de datos.

Se verificaron:

- tipos de datos,
- estructura de columnas,
- consistencia de formatos,
- integridad de registros.

El dataset incluía intencionalmente:

- valores nulos,
- duplicados,
- formatos incorrectos,
- categorías inválidas,
- inconsistencias de negocio.

Estos registros permitieron simular escenarios reales de calidad de datos.

Tratamiento Duplicados

Los duplicados no fueron eliminados automáticamente. En entornos financieros es posible que dos operaciones legítimas compartan características similares sin representar un error. Por esta razón se realizó una evaluación contextual antes de tomar decisiones de limpieza.

Tratamiento de outliers

Los valores extremos fueron preservados. En problemas de fraude financiero, los comportamientos atípicos suelen contener información valiosa y pueden representar eventos fraudulentos reales.

4. Catalogo de Variables

Uno de los aspectos más importantes del proyecto fue la selección adecuada de variables para el entrenamiento de los modelos predictivos. Debido a que el dataset fue generado sintéticamente, algunas variables fueron construidas utilizando las mismas reglas que posteriormente determinaron la etiqueta de fraude (fraud_label).

Si estas variables hubieran sido utilizadas, los modelos habrían tenido acceso indirecto a información relacionada con la respuesta correcta, generando un fenómeno conocido como **Data Leakage** o fuga de información.

La fuga de información ocurre cuando el modelo utiliza variables que contienen conocimiento del resultado que intenta predecir. Esto produce métricas artificialmente elevadas y modelos que no generalizan correctamente a escenarios reales.

Por esta razón, se realizó una revisión detallada de cada variable del dataset para determinar su elegibilidad dentro del proceso de entrenamiento.

Variable	Descripción y Rol	Tipo / Uso
transaction_id	Identificador único por transacción. Se excluye como predictor (no aporta información estadística).	Temporal / ID
customer_id	Identificador del cliente. Se excluye para prevenir fuga de información.	Temporal / ID
transaction_datetime	Fecha y hora exacta. Se descompone en date y time. Excluida como cruda.	Temporal / ID
transaction_date	Fecha de la transacción. Variable temporal derivada.	Temporal / ID
transaction_time	Hora de la transacción en formato HH:MM:SS. Estandarizada con regex.	Temporal / ID
transaction_amount	MONTO de la transacción. Variable numérica central del análisis de riesgo.	Predictora
product_type	Tipo de producto financiero (ej. transferencia, crédito). Variable categórica.	Predictora
channel	Canal de la transacción: web, app, agente, etc. Variable categórica clave.	Predictora

transaction_status	Estado de la transacción. Variable categórica.	Predictora
transaction_direction	Dirección del movimiento (entrada/salida). Variable categórica.	Predictora
customer_segment	Segmento del cliente. Variable categórica de comportamiento.	Predictora
occupation / industry / employment_type	Variables sociodemográficas del cliente.	Predictora
income_frequency / monthly_income	Frecuencia e ingreso mensual del cliente.	Predictora
customer_tenure_months	Antigüedad del cliente en meses.	Predictora
avg_3m_transaction_amount	Promedio del monto de transacciones en los últimos 3 meses. Variable de comportamiento histórico.	Predictora
avg_3m_transaction_count	Promedio del número de transacciones en los últimos 3 meses.	Predictora
usual_product_type / usual_channel	Producto y canal habituales del cliente. Base para detección de desviaciones.	Predictora
usual_transaction_hour_range	Rango horario habitual del cliente.	Predictora
deviation_from_usual_amount_pct	Porcentaje de desviación del monto respecto al comportamiento habitual. EXCLUIDA por riesgo de leakage.	EXCLUIDA — Leakage
risk_score	Puntuación de riesgo (0-100). EXCLUIDA: derivada del proceso que genera fraud_label.	EXCLUIDA — Leakage
risk_profile	Categoría de riesgo del cliente. EXCLUIDA por misma razón que risk_score.	EXCLUIDA — Leakage
anomaly_flag	Indicador binario de anomalía. EXCLUIDA: correlacionada directamente con fraud_label.	EXCLUIDA — Leakage
data_quality_flag	Indicador de calidad del registro: valid, dirty, duplicate, null_issue, invalid_format.	EXCLUIDA - CALIDAD
fraud_label	VARIABLE OBJETIVO. 0 = Transacción legítima. 1 = Transacción fraudulenta.	Variable Objetivo

Las variables coloreadas en naranja (risk_score, anomaly_flag, deviation_from_usual_amount_pct, risk_profile) fueron excluidas de todos los modelos

porque fueron generadas en el mismo proceso sintético que creó `fraud_label`. Incluirlas equivaldría a darle al modelo la respuesta antes del examen.

5. Análisis Exploratorio de Datos

Una vez completada la limpieza se realizó un análisis exploratorio orientado a comprender el comportamiento de las transacciones.

Las principales áreas evaluadas fueron:

- distribución de montos,
- comportamiento por canal,
- comportamiento por producto financiero,
- perfiles de riesgo,
- anomalías detectadas,
- distribución temporal.

Como resultado del análisis, se identificaron varios hallazgos relevantes:

Concentración del fraude por canal

Los canales **web**, **app** y **agente** concentraron la mayor cantidad de transacciones fraudulentas detectadas. Este comportamiento sugiere una mayor exposición al riesgo en canales digitales y de atención indirecta, donde las validaciones presenciales son limitadas.

Concentración del fraude por producto financiero

Las **transferencias cuenta a cuenta** representaron el producto con mayor incidencia de fraude dentro del conjunto de datos. Este resultado es consistente con escenarios reales, donde las transferencias permiten movilizar fondos rápidamente y presentan una mayor superficie de riesgo.

Relación entre riesgo, anomalías y fraude

Durante el análisis se observó una fuerte asociación entre los indicadores de riesgo y las transacciones fraudulentas. Variables como `risk_score`, `risk_profile` y `anomaly_flag` mostraron una correlación significativa con la variable objetivo `fraud_label`.

Debido a esta relación directa con el proceso de generación sintética del fraude, dichas variables fueron posteriormente excluidas del entrenamiento de los modelos para evitar problemas de Data Leakage.

Comportamiento anómalo de las transacciones fraudulentas

Las transacciones marcadas como fraude tendían a presentar características distintas al comportamiento histórico de los clientes, incluyendo cambios en canales habituales, horarios de operación y montos significativamente diferentes a sus patrones normales de actividad.

Estos hallazgos permitieron comprender mejor la naturaleza del problema y sirvieron como base para la selección de variables, el diseño de los modelos predictivos y la construcción de los dashboards ejecutivos desarrollados en Power BI.

6. Modelado

Una vez el dataset está limpio, comienza la etapa de modelado. Se siguen dos enfoques complementarios: primero modelos no supervisados (que aprenden sin etiquetas) y luego modelos supervisados (que aprenden de la etiqueta `fraud_label`).

El equipo decidió comparar dos enfoques distintos para la detección de fraude.

6.1 Enfoque Supervisado

Los modelos supervisados aprenden directamente de la etiqueta `fraud_label`. Con el dataset sintético y sus patrones marcados, ambos modelos lograron resultados extremadamente altos.

Logistic Regression

Es un algoritmo de clasificación supervisada que estima la probabilidad de que una transacción pertenezca a una determinada clase.

En este proyecto, el modelo aprende a calcular la probabilidad de que una transacción sea fraudulenta utilizando ejemplos históricos etiquetados mediante la variable objetivo `fraud_label`.

Su funcionamiento se basa en identificar relaciones entre las variables predictoras y la probabilidad de fraude.

Por ejemplo, el modelo puede aprender patrones como:

- montos inusualmente altos,
- canales de operación específicos,
- determinados perfiles de clientes,
- comportamientos transaccionales atípicos.

A partir de estas relaciones, genera una probabilidad comprendida entre 0 y 1.

Posteriormente, esa probabilidad se transforma en una clasificación:

- 0 = Transacción legítima
- 1 = Transacción fraudulenta

Randon Forest

Es un algoritmo supervisado basado en un conjunto de árboles de decisión.

En lugar de depender de una única estructura de decisión, el modelo construye múltiples árboles independientes y posteriormente combina sus resultados para obtener una predicción final.

Cada árbol analiza diferentes subconjuntos de datos y variables.

Finalmente, el modelo realiza una votación entre todos los árboles para determinar si una transacción debe clasificarse como fraudulenta o legítima.

Por ejemplo, Random Forest puede aprender combinaciones de factores como:

- canal utilizado,
- monto de la transacción,
- comportamiento histórico,
- perfil del cliente,

y detectar situaciones de riesgo que dependen de múltiples variables simultáneamente.

6.2 Enfoque no Supervisado

Los modelos no supervisados se entrenan sin usar `fraud_label`. Su propósito es detectar comportamientos anómalos de forma autónoma, útil en escenarios donde no existen etiquetas de fraude históricas.

Isolation Forest

Isolation Forest detecta anomalías construyendo árboles de decisión aleatorios. La premisa matemática es intuitiva: un punto anómalo se aísla con muy pocas particiones

K-Means

K-Means agrupa las transacciones en K clusters basándose en la similitud de sus variables. No predice fraude directamente: en cambio, permite identificar qué grupo concentra la mayor proporción de transacciones fraudulentas al evaluar sus resultados contra `fraud_label` de forma auxiliar.

Modelo Combinado: Isolation Forest + K-Means

Se construye un score compuesto sumando las señales de ambos modelos. Cada modelo que marca una transacción como sospechosa aporta +1 al score final.

```
df_model['score_no_supervisado'] = 0

# Señal 1: anomalía detectada por Isolation Forest
df_model.loc[df_model['isolation_anomaly'] == 1, 'score_no_supervisado'] += 1

# Señal 2: pertenece al cluster más riesgoso de K-Means
df_model.loc[df_model['kmeans_cluster_riesgoso'] == 1, 'score_no_supervisado'] += 1

# Clasificación por nivel de riesgo
df_model['riesgo_no_supervisado'] = np.select(
    [df_model['score_no_supervisado'] == 0,
     df_model['score_no_supervisado'] == 1,
     df_model['score_no_supervisado'] >= 2],
    ['bajo riesgo', 'riesgo medio', 'alto riesgo'],
    default='sin clasificar'
)
```

7. Evaluación de Modelos

Se evaluaron todos los modelos con el mismo conjunto de métricas para garantizar comparabilidad. En detección de fraude, Recall es la métrica más crítica: mide qué porcentaje de los fraudes reales el modelo detectó. Un Recall bajo tiene consecuencias económicas directas.

Modelo	Tipo	Recall	Precision	F1	ROC AUC
Isolation Forest	No supervisado	23.89%	18.16%	20.63%	55.96%
K-Means	No supervisado	45.61%	15.08%	22.67%	58.54%
Combinado (IF+KM)	No supervisado	62.60%	15.37%	24.67%	62.14%
Logistic Regression	Supervisado	99.95%	99.89%	99.92%	100%
Random Forest	Supervisado	99.91%	100%	99.96%	100%

8. Consolidación y Exportación para Power BI

Luego de finalizar las fases de limpieza, validación, análisis exploratorio, entrenamiento y evaluación de modelos de Machine Learning.

Antes de generar el dataset final se realizó una validación de las variables disponibles en memoria para identificar correctamente las predicciones, probabilidades y modelos entrenados.

Esta validación permitió asegurar que los resultados necesarios para la visualización estuvieran correctamente generados y disponibles para su posterior exportación.

Creación de Variables de Negocio

Para facilitar la interpretación de los resultados en Power BI se generaron variables adicionales orientadas al negocio.

Nivel de Riesgo Random Forest

Las probabilidades generadas por Random Forest fueron segmentadas en tres categorías:

- Bajo Riesgo
- Medio Riesgo
- Alto Riesgo

Esta clasificación permite identificar rápidamente transacciones con diferente nivel de exposición al fraude.

Score de Riesgo Porcentual

Finalmente se exportaron dos archivos:

dashboard_fraude_final.csv

Contiene:

- Información original de las transacciones
- Resultados de modelos supervisados
- Resultados de modelos no supervisados
- Scores de riesgo
- Clasificaciones de riesgo

Este archivo constituye la fuente principal del dashboard ejecutivo.

metricas_modelos.csv

Contiene:

- Recall
- Precision
- F1 Score
- ROC AUC

para cada uno de los modelos evaluados durante el proyecto.

Este archivo permite construir visualizaciones comparativas de desempeño y justificar la selección del modelo final.

La consolidación de los resultados permitió transformar modelos de Machine Learning y métricas técnicas en indicadores de negocio fácilmente interpretables mediante Power BI, facilitando la comunicación de hallazgos, la comparación de modelos y la toma de decisiones basada en datos.

9. Decisiones Técnicas Tomadas

Este capítulo reúne las decisiones de diseño más importantes del código. Cada una tiene un impacto directo en la calidad del análisis o en la confiabilidad de las métricas.

Decisión Técnica	Justificación
No eliminar duplicados ni outliers	En finanzas, dos transacciones idénticas pueden ser legítimas. Los outliers en montos suelen ser la señal más fuerte de fraude.
Filtrar solo registros 'valid'	Entrenar con datos de baja calidad contamina el modelo. Los registros no válidos se conservan aparte para auditoría.
Escalar solo con X_train	Ajustar el StandardScaler también sobre X_test significaría que el modelo 'vía' información futura durante el entrenamiento. Eso invalida las métricas.
class_weight='balanced'	El dataset tiene 90% de transacciones legítimas y 10% fraudulentas. Sin este parámetro el modelo aprendería a predecir siempre 'legítima' y aún así tendría 90% de accuracy.
Excluir risk_score / anomaly_flag	Estas variables fueron generadas junto con fraud_label en el proceso sintético. Incluirlas sería equivalente a entrenar con la respuesta ya conocida.
Modelos no supervisados primero	Los modelos sin etiqueta ayudan a entender la estructura natural de los datos antes de aplicar supervisión. Además, en producción real a veces no existen etiquetas de fraude.

10. Glosario Técnico

Término	Definición
Data Leakage	Fuga de información del futuro hacia el entrenamiento del modelo. Ocurre cuando el modelo tiene acceso a datos que no estarían disponibles en producción, inflando artificialmente las métricas.
Recall (Sensibilidad)	Proporción de fraudes reales que el modelo detectó correctamente. $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$. Es la métrica más crítica en fraude porque un FN implica un fraude no detectado.
Precision	Proporción de alertas del modelo que son fraudes reales. $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$. Precision baja implica muchas falsas alarmas.
F1 Score	Media armónica de Precision y Recall. Útil cuando hay desbalance de clases y se necesita equilibrar ambas métricas.

ROC AUC	Área bajo la curva ROC. Mide la capacidad del modelo para distinguir entre clases (0 y 1). 0.5 = azar, 1.0 = perfecto.
IQR	Rango Intercuartílico: Q3 - Q1. Mide la dispersión del 50% central de los datos. Se usa para detectar outliers de forma robusta sin asumir distribución normal.
class_weight='balanced'	Parámetro que hace que el modelo trate a las clases minoritarias con más peso. Equivale a multiplicar el error en la clase minoritaria por $n_{\text{mayoritaria}} / n_{\text{minoritaria}}$.

11. Conclusión

Este proyecto permitió desarrollar una solución integral de monitoreo, análisis de riesgo y detección de fraude financiero, aplicando un pipeline completo de Ciencia de Datos que abarca desde la calidad y preparación de los datos hasta la construcción de modelos predictivos y la visualización de resultados para la toma de decisiones.

Cada decisión técnica implementada respondió a principios estadísticos y necesidades de negocio, garantizando un proceso metodológicamente sólido. La comparación entre modelos supervisados y no supervisados permitió responder la pregunta central del proyecto: ¿qué diferencia existe entre detectar fraude cuando se dispone de etiquetas históricas y cuando no se tienen? Y ¿Cómo Aplicar modelos no supervisor y supervisados en un mismo proyecto? Los resultados demostraron que los modelos supervisados alcanzan una capacidad predictiva significativamente superior, mientras que los no supervisados continúan aportando valor en la detección temprana de anomalías y en escenarios donde no existe información etiquetada.

Asimismo, la integración de Power BI permitió transformar resultados técnicos en indicadores comprensibles para perfiles ejecutivos, de riesgo y de cumplimiento, cerrando el ciclo entre análisis y negocio. Más allá del rendimiento de los modelos, el principal aporte del proyecto radica en demostrar cómo una organización puede combinar calidad de datos, análisis exploratorio, segmentación de riesgo, detección de anomalías, Machine Learning y visualización para convertir grandes volúmenes de información financiera en conocimiento accionable para la prevención del fraude y la toma de decisiones basada en datos.